



第9章 数字滤波器实现中的有限字长效应

引言

9.1 二进制算法基础

9.2 A/D变换的量化效应

9.3 数字滤波器定点制运算中的有限字长效应



引言

数字系统中共有三种因量化而引起的误差因素：

- (1) A/D变换引起的量化效应；
- (2) 系数的量化效应；
- (3) 数字运算过程中的有限字长效应。

例如，十进制两位数乘法 $0.86 \times 0.51 = 0.4386$ ，若只有两位有效小数位，则结果处理有“舍入”为0.44或截取为0.43。



9.1 二进制算法基础

二进制数的描述和量化影响

1. 定点制表示法

在整个运算中，小数点在数码中的位置是固定不变的。

如： $M = 101.1101$

小数点在第三位，则在整个运算中，小数点始终都在第三位不变。

十进制数为：

$$(1 \times 2^2 + 0 \times 2^1 + 1 \times 2^0) + (1 \times 2^{-1} + 1 \times 2^{-2} + 0 \times 2^{-3} + 1 \times 2^{-4})$$



■ 通常表示:

(定点: $|x| < 1$, 或 $-1 < x < 1$)

这样, 就把小数点规定在第一位二进码之前, 而把整数位作为“符号位”, 代表数的正负; 数的本身只有小数部分称为“尾数”。

例如: **0.75**则表示为**0.110**; **0.125**则表示为**0.001**.

■ 运算:

定点制在整个运算过程中, 所有运算结果的绝对值都不超过1。

在实际问题中, 数可能很大, 这时应对运算过程中的各数乘以某一比例因子, 使整个运算中数的最大绝对值不超过1。

运算完毕后再除以比例因子, 从而还原为真实输出。



- 定点制中任何加法运算不会增加字长，例如四位长的两数相加

$$\begin{array}{r} 0.0110 \\ + 0.0011 \\ \hline 0.1001 \end{array}$$

✓溢出!!!

$$\begin{array}{r} 0.1010 \\ + 0.0111 \\ \hline \textcircled{1}.0001 \end{array}$$



■ 定点制中任何乘法运算都不会造成溢出，因为绝对值小于1的两个数相乘后绝对值仍然小于1

✓ 字长要增加!!!

例如：字长为三位的两数： $x=0.101, y=0.011$

相乘后， $xy=0.001111$

通常，乘法运算需要“截尾”或者“舍入”（有限长效应）

小结

定点制的缺点是动态范围小，有溢出的问题。



浮点型

优点：有很大的动态范围，溢出的可能性小，不需要比例因子

浮点制是将一个数表达为尾数和指数两部分：

$$x = \pm M \times 2^c$$

其中， M 是尾数部分， 2^c 是指数部分， c 是阶数，称为“阶码”。

例如： $x = 0.101 \times 2^{101}$ 对应的十进制数为 $x = 0.625 \times 2^5 = 20$



浮点制中为了充分利用尾数的有效位数，总使得尾数的第一位为1，这称为归一化形式，因此尾数范围为 $\frac{1}{2} \leq M < 1$

尾数字长决定浮点制的运算精度，而阶码的字长决定了浮点制的动态范围。

- 浮点制的乘法是尾数相乘、阶码相加；该过程与定点制相同，因此也要做截尾或舍入的处理。



浮点制相加

- ✓ 对位，使两数的阶码相等
- ✓ 相加
- ✓ 使结果归一化并作尾数处理

例如： $x = 0.1010 \times 2^{100}$, $y = 0.1101 \times 2^{010}$ 相加

1) 将 y 调整到 $y = 0.001101 \times 2^{100}$

2) x 与 y 相加:

$$\begin{array}{r} 0.1010 \times 2^{100} \\ + 0.001101 \times 2^{100} \\ \hline 0.110101 \times 2^{100} \end{array}$$

3) 尾数截取或舍入处理： $x + y = 0.1101 \times 2^{100}$

浮点制的优点：动态范围大，一般不需要考虑溢出。

但是，不论相乘或者相加，都需要作尾数量化处理，因此有量化误差。



负数表示法

原码、补码、反码

不论是定点制还是浮点制的尾数都是将整数位作为符号位，其一般的（**b+1**）位的形式为：

$$\beta_0 \ \beta_1 \beta_2 \cdots \beta_b \quad (9-1)$$

每一个 β_i 代表第 i 位二进制码，可以取**0**或者**1**。

β_0 代表符号位， β_1 至 β_b 代表**b**位字长的尾数值。



(1) 原码

原码也称为“符号——幅度码”，它的尾数部分代表数的绝对值（即其幅度大小），符号位代表数的正负号，一般 $\beta_0 = 0$ 表示正数， $\beta_0 = 1$ 表示负数。

原码为 $\beta_0 \beta_1 \beta_2 \cdots \beta_b$ 所代表的十进制数值为：

$$x = (-1)^{\beta_0} \sum_{i=1}^b \beta_i 2^{-i} \quad (9-1)$$

例： $x = 0.110$ 所表示的十进制数是 **+0.75**

$x = 1.110$ 所表示的十进制数是 **-0.75**



原码的**优点**是乘除运算方便，不论正负数乘除运算都一样，并以符号位简单地决定结果的正负号。

但加减运算不方便，因为两数相加，先要判断两数符号是否相同。若相同则做加法，若不同则做减法。

此外，还要判断两数绝对值的大小，以使用大值减去小值。



(2) 补码

补码中负数是采用2的补数来表示。也即当 x 为负数时，则用 x 对2的补数 x_c 代表 x 。

x_c 的十进制数可按以下公式计算：

$$x_c = 2 - |x| \quad (9-3)$$

例如， $x = -0.75$ ，在原码中表示为1.110，

在补码中 $x_c = 2 - 0.75 = 1.25$ ，因此补码表示为1.010，这里整数1代表了负数。



对于式（9-1）所表示的一般形式，补码所代表的十进制数值可表示为：

$$x = -\beta_0 + \sum_{i=1}^b \beta_i 2^{-i} \quad (9-4)$$

例如，补码1.110，按照（9-4）式可知其表示的数为：

$$x = -1 + 0.75 = -0.25$$

采用补码后，加法运算较为方便，不论数的正负，都可直接相加，而且符号位也同样参加运算，如果符号位发生进位，把进位的1丢掉即可。



(3) 反码

将该负数正数表示形式中的所有0改为1，所有1改为0，即为对应负数的反码表示。

例如 $x = -0.625$ ，其正数表达式为0.101，将其0和1全部颠倒则为1.010，即为 x 的反码表示。

负数的反码与补码表达之间有简单的对应关系，即补码等于反码在最低位上加1。

例如， $x = -0.625$ ，反码表示为1.010，补码表示则为1.011。这个最低位的加1，代表加一个 2^{-b} 。因此反码的数值可以表达为：

$$x = -\beta_0(1 - 2^{-b}) + \sum_{i=1}^b \beta_i 2^{-i}$$

采用反码后加法运算也较为方便。



三 量化方式：截尾与舍入

不论是定点制中的乘法还是浮点制的乘法和加法，运算完毕后都会使字长增加。

例如原来是 b 位字长，运算后增加到 b_l 字长，因此都需要对尾数做量化处理使 b_l 位字长缩减为 b 位字长。

截尾处理是保留 b 位码，舍去余下的尾数；

舍入处理使按最接近的值取 b 位码。

以上两种处理方法所产生的误差是不一样的，同时不同的码值所得结果也不一样。



(1) 定点制的截尾与舍入误差

✓ 截尾处理

对于正数，三种码的形式都是相同的，即一个 b_l 位的正数 x 为：

$$x = \sum_{i=1}^{b_l} \beta_i 2^{-i}$$

以 $[\cdot]$ 表示量化处理，以 $[\cdot]_T$ 表示截尾处理，因此有：

$$[x]_T = \sum_{i=1}^b \beta_i 2^{-i}$$



则截尾误差为：
$$E_T = [x]_T - x = - \sum_{i=b+1}^{b_l} \beta_i 2^{-i}$$

上式表明截尾误差总是负的，并在 β_i 全部为1时，具有最大误差

$$E_T = - \sum_{i=b+1}^{b_l} 2^{-i} = - (2^{-b} - 2^{-b_l})$$

$$- (2^{-b} - 2^{-b_l}) \leq E_T \leq 0$$

一般 $2^{-b_l} \ll 2^{-b}$ ，并令 $q = 2^{-b}$ 为最小码位所代表的数值，称为“量化宽度”或“量化阶”。因此，正数的截尾误差为：

$$-q \leq E_T \leq 0$$



对于负数，由于三种码的表示方式不同，误差也不同。

■对于原码 ($\beta_0 = 0$) : $x = -\sum_{i=1}^{b_l} \beta_i 2^{-i}$

$$[x]_T = -\sum_{i=1}^b \beta_i 2^{-i}$$

$$E_T = [x]_T - x = \sum_{i=b+1}^{b_l} \beta_i 2^{-i}$$

因此误差为正，即 $0 \leq E_T < q$

例如， b_l 为四位， b 为两位时，负数 $x = 1.1010(-0.625)$ ，

$$[x]_T = 1.10(-0.5), E_T = [x]_T - x = -0.5 - (-0.625) = 0.125 > 0$$



■补码的负数表示为 ($\beta_0 = 1$) :

$$x = -1 + \sum_{i=1}^{b_l} \beta_i 2^{-i}$$

$$[x]_T = -1 + \sum_{i=1}^b \beta_i 2^{-i}$$

$$-q \leq E_T \leq 0$$



■反码的负数表示为 ($\beta_0 = 1$) :

$$x = -1 + \sum_{i=1}^{b_1} \beta_i 2^{-i} + 2^{-b_1}$$

$$[x]_T = -1 + \sum_{i=1}^b \beta_i 2^{-i} + 2^{-b}$$

$$E_T = [x]_T - x = -\sum_{i=b+1}^{b_1} \beta_i 2^{-i} + (2^{-b} - 2^{-b_1})$$

$$0 \leq E_T < q$$

E_T 为正值。



例如, $x = 1.1000(-0.4375)$

$$[x]_T = 1.10(-0.5), E_T = [x]_T - x = -0.25 - (-0.4375) = 0.1875 > 0$$



小 结

- ✓ 补码的截尾误差都是负值，其量化处理的非线性特性如图9.1(a)所示。
- ✓ 原码与反码的截尾误差与数的正负有关，正数时为负，负数时为正，其量化处理的非线性特性如图9.1(b)所示。





✓ 舍入处理

对于舍入处理，由于是按最接近的数量化，所以不论正数、负数，也不论是原码、补码、反码，其误差总是在 $\pm q/2$ 之间。

以 $[x]_R$ 表示舍入误差：

$x = 0.1001$, $[x]_R = 0.10$ 舍去0.0001，误差为 -2^{-4}

$x = 0.1011$, $[x]_R = 0.11$ ，将0.0011取入为0.01，误差为 $+2^{-4}$

$x = 0.1010$ ，则 x 与0.10及0.11距离相等，因此既可以令 $[x]_R = 0.10$

也可以取 $[x]_R = 0.11$ 。这一点的选择对误差影响不大，一般可按**四舍五入，逢5进1**，因此取：

$$[x]_R = 0.11$$



对于补码，舍入处理可表示为：


$$x = -\beta_0 + \sum_{i=1}^{b_l} \beta_i 2^{-i}$$

$$[x]_R = -\beta_0 + \sum_{i=1}^b \beta_i 2^{-i} + \beta_{b+1} 2^{-b}$$

最后一项代表逢5进1，其他码也可用类似方式表示。

此时，舍入误差为：

$$-q/2 < E_R < q/2$$





(2) 浮点制的截尾与舍入误差

在浮点制中截尾或舍入的处理只影响尾数的字长，但是所产生的误差大小却与阶码的值有关。

例如： x_1 与 x_2 为两个不同阶码的数：

$$x_1 = 0.1001 \times 2^{000} (= 0.5625)$$

$$[x_1] = 0.1 \times 2^{000} (= 0.50)$$

$$E_1 = [x_1] - x_1 = -0.0625$$

$$x_2 = 0.1001 \times 2^{011} (= 4.5)$$

$$[x_2] = 0.1 \times 2^{011} (= 4.0)$$

$$E_2 = [x_2] - x_2 = -0.5$$

从上面两个数可以看出，在同样的尾数舍去的情况下，由于 x_1 比 x_2 大8倍，相应的量化误差 $|E_2|$ 比 $|E_1|$ 大8倍。



在浮点制中量化误差是与数字本身的大小有关的，所以用相对误差比用绝对误差更能反映它的特点。这个相对的量化误差我们以 ε 定义为：

$$\varepsilon = \frac{[x] - x}{x}$$

此时，绝对误差可表示为：

$$E = [x] - x = \varepsilon x$$

这个误差是相乘性误差而不是像定点制的相对误差。



ε 的取值范围分析

当采用舍入处理时，尾数误差在 $\pm q/2$ 之间，设 x 的阶码为 c


则

$$-2^c q/2 < [x]_R - x \leq 2^c q/2$$



9.2 A/D变换的量化效应

ADC完成模拟信号的数字化，同样存在量化效应。其中，A/D可用截尾或舍入方式转化，此时量化误差考虑为“量化噪声” $e(n)$





A/D变换总是定点制的，必须使信号不超过A/D变换的动态范围，即 $x(n)$ 必须在 $(-1, 1)$ 之间。

第一步：

$$x(n) = Ax_a(nT)$$

$$x(n) = -\beta_0 + \sum_{i=1}^{\infty} \beta_i 2^{-i}$$

第二步：对 $x(n)$ 量化，使字长固定在 b 位，这个量化可以采用截尾或者舍入。

■ 对于截尾处理，有： $\hat{x}(n) = [x(n)]_T = -\beta_0 + \sum_{i=1}^b \beta_i 2^{-i}$

截尾的量化误差为： $e_T(n) = \hat{x}(n) - x(n) = - \sum_{i=1+b}^{\infty} \beta_i 2^{-i}$


$$-q < e_T(n) \leq 0, \quad q = 2^{-b}$$




■ 对于舍入处理，有： $\hat{x}(n) = [x(n)]_R = -\beta_0 + \sum_{i=1}^b \beta_i 2^{-i} + \beta_{b+1} 2^{-b}$

舍入的量化误差为： $e_R(n) = \hat{x}(n) - x(n)$

$$-q/2 < e_T(n) \leq q/2$$



截尾



舍入



一. 量化噪声的统计分析

假定：(1) $e(n)$ 为平稳随机过程

(2) $e(n)$ 与 $x(n)$ 不相关

(3) $e(n)$ 为白噪声


(4) $e(n)$ 均匀等概率分布

利用 $e(n)$ 的概率分布，计算出 $e(n)$ 的统计特性

$$\text{均值: } m_e = E[(e(n))] = \int_{-\infty}^{\infty} eP(e)de$$

$$\text{方差（噪声功率）: } \sigma_e^2 = E[(e(n) - m_e)^2] = \int_{-\infty}^{\infty} (e - m_e)^2 P(e)de$$

AD变换的量化噪声分析也可以分为截尾分布和舍入分布两种情况



1. 截尾:


均值: $m_e = -\frac{q}{2}$: 直流误差, 因此一般不用该量化、转换公式

方差: $\sigma_e^2 = \frac{q^2}{12}$


2. 舍入:


均值: $m_e = 0$


方差: $\sigma_e^2 = \frac{q^2}{12}$ $q = \Delta = 2^{-b}$




物理意义: A/D字长 $b \uparrow$, 则 $\sigma_e^2 \downarrow$, 噪声下降, 性能提高。











例如：

A/D变换时基于信号 $x(n)$ 的方差与噪声 $e(n)$ 的方差定义的信噪比为：

$$\begin{aligned}\text{SNR} &= 10 \log_{10} \frac{\sigma_x^2}{\sigma_e^2} = 10 \log_{10} \sigma_x^2 - 10 \log_{10} \sigma_e^2 \\ &= 10.79 + 6.02b + 10 \log_{10} \sigma_x^2\end{aligned}$$

令 $\sigma_x^2 = 1$

$$\text{SNR} = 10.79 + 6.02b$$


$$b = 10, \quad \text{SNR} = 71\text{dB}$$

$$b = 15, \quad \text{SNR} = 101\text{dB}$$



二. 量化噪声通过系统

实际应用中有意义的信号是随机信号，其量化误差也是随机信号，这样无论信号或噪声都可用相同的方法进行分析。为单独分析系统对随机信号的影响，将系统近似为如图所示的无限精度的线性系统。





因为线性相加的随机信号，经过线性系统仍是线性相加的，所以上图中系统的输出为

$$\hat{y}(n) = y(n) + e_f(n)$$

式中 $y(n)$ 是信号输出， $e_f(n)$ 是噪声输出。

假设 $e(n)$ 为白色平稳随机过程，输入与输出的均值关系如下

$$m_e = E[e(n)] \qquad m_f = E[f(n)]$$



将

$$\begin{aligned}\hat{y}(n) &= \hat{x}(n) * h(n) = (x(n) + e(n)) * h(n) \\ &= x(n) * h(n) + e(n) * h(n)\end{aligned}$$

因此，输出噪声可表示为

$$e_f = e(n) * h(n)$$

代入上式，且平稳随机过程其均值与 n 、 m 无关，所以

$$\begin{aligned}m_f &= \sum_{m=0}^{\infty} h(m) E[e(n-m)] = m_e \sum_{m=0}^{\infty} h(m) \\ &= m_e H(e^{j0})\end{aligned}$$

特别的，若 $m_e=0$ ，则 $m_f=0$ 。



输入与输出噪声的均值关系可类推，即

$$m_f = m_e \sum_{m=0}^{\infty} h(m) = m_e H(e^{j0})$$

式中 $h(n)$ 是噪声 $e(n)$ 到输出节点的单位脉冲响应，

$H_e(e^{j0})$ 是噪声频响在零频时的数值。



再假设输入是零均值的白色平稳随机过程，则输入信号与输出信号的方差（功率）关系如下：

$$\begin{aligned}\sigma_f^2 &= E[e_f^2(n)] = E\left[\sum_{m=0}^{\infty} h(m)e(n-m) \sum_{l=0}^{\infty} h(l)e(n-l)\right] \\ &= \sum_{m=0}^{\infty} \sum_{l=0}^{\infty} h(m)h(l)E[e(n-m)e(n-l)]\end{aligned}$$

因为 $e(n)$ 为白色随机过程，序列各变量之间互不相关，所以上式中

$$E[e(n-m)e(n-l)] = \delta(m-l)\sigma_e^2$$



将结果代入 $\sigma_f^2 = E[e_f^2(n)]$ ，则

$$\sigma_f^2 = E \left[\sum_{m=0}^{\infty} \sum_{l=0}^{\infty} h(m)h(l)\delta(m-l)\sigma_e^2 \right] = \sigma_e^2 \sum_{m=0}^{\infty} h^2(m)$$



由帕塞伐定理

$$\begin{aligned}\sigma_f^2 &= \sigma_e^2 \sum_{m=0}^{\infty} h^2(m) = \\ &= \frac{\sigma_e^2}{2\pi j} \oint_c H(z)H(z^{-1}) \frac{dz}{z}\end{aligned}$$

或者

$$\sigma_f^2 = \frac{\sigma_e^2}{2\pi} \int_{-\pi}^{\pi} |H(e^{j\omega})|^2 d\omega$$




式中 $h(n)$ 是噪声 $e(n)$ 到输出节点的单位脉冲响应, $H(e^{j\omega})$ 是对应的系统频响, $H(z)$ 是 $h(n)$ 的Z变换。

以上结果适用任意白色平稳随机信号通过线性系统分析,在以后相关各节将不再说明的引用。



小结 量化噪声通过系统



输出噪声功率

$$\sigma_f^2 = \frac{\sigma_e^2}{2\pi} \int_{-\pi}^{\pi} |H(e^{j\omega})|^2 d\omega$$

输出噪声直流


$$m_f = m_e \sum_{m=0}^{\infty} h(m) = m_e H(e^{j0})$$




9.3 数字滤波器定点制运算中的有限字长效应

■ IIR系统定点舍入运算的误差分析

定点运算中，每一次乘法运算之后，都要作一次尾数处理(舍入或截尾)，由此引入误差。




(a) 理想相乘



(b) 实际相乘舍入的非线性流图



利用统计分析方法，可以将误差等效为独立的噪声叠加在信号上，如图 (c)所示：



(c) 实际相乘的定点舍入噪声统计模型的线性流图

因为一般尾数处理多采用舍入，所以设 $Q[\]$ 是舍入处理，则 $e(n)$ 为舍入误差。



为分析方便，对 $e(n)$ 再作如下假设

- (1) 所有误差 $e(n)$ 是平稳的零均值白噪声序列；
- (2) 每个误差在量化误差范围内均匀等概分布；
- (3) 两个不同噪声源彼此不相关；
- (4) 误差 $e(n)$ 与输入 $x(n)$ 不相关，且与系统中任何节点变量不相关，从而与输出 $y(n)$ 也不相关。



根据以上假定，及舍入误差范围 $(-2^{-b}/2 \sim 2^{-b}/2)$ ，可以得到其均值为零，方差为

$$\sigma_e^2 = E[e^2(n)] = \frac{2^{-2b}}{12} = \frac{q^2}{12}$$

采用统计方法，实际输出可以表示为

$$\hat{y}(n) = y(n) + f(n)$$

式中 $f(n)$ 是由噪声产生的输出，其均值与方差为

$$m_f = m_e \sum_{m=0}^{\infty} h(m) = m_e H(e^{j0}) \quad (9.4-13)$$



$$\sigma_f^2 = \sigma_e^2 \sum_{m=0}^{\infty} h^2(m) = \frac{\sigma_e^2}{2\pi j} \oint_c H(z)H(z^{-1}) \frac{dz}{z}$$

式中 $h(m)$ 是噪声 $e(n)$ 到输出节点的的单位脉冲响应,

$H(z)$ 是 $h(m)$ 的 z 变换。

因为均值为零的信号，其方差与平均功率相同，所以计

算零均值噪声的方差就是计算噪声的平均功率。



例9.4-1 二阶IIR低通滤波器，传递函数为：

$$H(z) = \frac{0.04}{(1-0.9z^{-1})(1-0.8z^{-1})}$$

采用定点舍入尾数处理，分别计算直接型、一阶节级联、
并联三种结构舍入误差的方差。


解：(1)直接型的系统函数

$$H(z) = \frac{0.04}{1-1.7z^{-1}+0.72z^{-2}}$$




直接型定点舍入相乘的统计模型如图 (a)所示， 由图可见有三次乘法运算，

产生三个噪声源。



(a)




(b)

图(b)是噪声的统计模型，利用线性系统叠加性计算输出噪声的方差。



$$e_1(n) + e_2(n) + e_3(n)$$

$f(n)$



由图得到噪声的传输函数

$$H(z) = \frac{1}{(1-0.9z^{-1})(1-0.8z^{-1})} = \frac{9}{1-0.9z^{-1}} - \frac{8}{1-0.8z^{-1}}$$

对应的单位脉冲响应

$$h(n) = [9(0.9)^n - 8(0.8)^n]u(n)$$



则 $f(n)=[e_1(n)+e_2(n)+e_3(n)]*h_e(n)$


$$\begin{aligned}\sigma_f^2 &= [\sigma_{e1}^2 + \sigma_{e2}^2 + \sigma_{e3}^2] \sum_{n=0}^{\infty} h_e^2(n) \\ &= 3\sigma_{e1}^2 \sum_{n=0}^{\infty} [9(0.9)^n - 8(0.8)^n]^2 \\ &= 3\sigma_{e1}^2 \sum_{n=0}^{\infty} [81(0.9)^{2n} - 2 \times 8 \times 9(0.72)^n + 64(0.8)^{2n}] \\ &= 22.4 \times 2^{-2b}\end{aligned}$$



(2) 级联型

$$H(z) = \frac{0.04}{1-0.9z^{-1}} \cdot \frac{1}{1-0.8z^{-1}}$$

级联型定点舍入相乘的统计模型如图所示,



由图可见有三次乘法运算, 产生三个噪声源。可利用线性系统性质分别计算输出噪声的方差。



由图可见, $e_1(n)$ 与 $e_2(n)$ 的传递函数相同, 即

$$\begin{aligned} H_1(z) &= H_2(z) \\ &= \frac{1}{(1-0.9z^{-1})(1-0.8z^{-1})} = \frac{9}{1-0.9z^{-1}} - \frac{8}{1-0.8z^{-1}} \end{aligned}$$

$e_3(n)$ 的传递函数

$$H_3(z) = \frac{1}{1-0.8z^{-1}} \leftrightarrow h_3(n) = 0.8^n u(n)$$

$$f(n) = [e_1(n) + e_2(n)] * h_1(n) + e_3(n) * h_3(n)$$




$$\begin{aligned}\sigma_f^2 &= [\sigma_{e_1}^2 + \sigma_{e_2}^2] \sum_{n=0}^{\infty} h_{e_1}^2(n) + \sigma_{e_3}^2 \sum_{n=0}^{\infty} h_{e_3}^2(n) \\&= 2\sigma_{e_1}^2 \times 89.8 + \sigma_{e_3}^2 \sum_{n=0}^{\infty} (0.8)^{2n} \\&= \frac{2^{-2b}}{6} \times 89.8 + \frac{2^{-2b}}{12} \cdot \frac{1}{1-0.64} \\&= 15.2 \times 2^{-2b}\end{aligned}$$



(3) 并联型
$$H(z) = \frac{0.36}{1-0.9z^{-1}} + \frac{-0.32}{1-0.8z^{-1}}$$

并联型定点舍入相乘的统计模型如图所示



由图可见有四次乘法运算，产生四个噪声源，同样可利用线性系统性质分别计算输出噪声的方差。



由图可见, $e_1(n)$ 与 $e_2(n)$ 的传递函数相同, 即

$$H_1(z)=H_2(z)=\frac{1}{1-0.9z^{-1}} \leftrightarrow h_1(n)=0.9^n u(n)$$

$e_3(n)$ 与 $e_4(n)$ 的传递函数相同, 即

$$H_3(z)=H_4(z)=\frac{1}{1-0.8z^{-1}} \leftrightarrow h_3(n)=0.8^n u(n)$$

$$f(n)=[e_1(n)+e_2(n)]*h_1(n)+[e_3(n)+e_3(n)]*h_3(n)$$



$$\begin{aligned}\sigma_f^2 &= [\sigma_{e1}^2 + \sigma_{e2}^2] \sum_{n=0}^{\infty} h_{e1}^2(n) + [\sigma_{e3}^2 + \sigma_{e4}^2] \sum_{n=0}^{\infty} h_{e3}^2(n) \\&= 2\sigma_{e1}^2 \sum_{n=0}^{\infty} [h_{e1}^2(n) + h_{e3}^2(n)] \\&= \frac{2^{-2b}}{6} \left(\sum_{n=0}^{\infty} (0.9^{2n} + 0.8^{2n}) \right) \\&= \frac{2^{-2b}}{6} \left(\frac{1}{1-0.81} + \frac{1}{1-0.64} \right) \\&= \frac{2^{-2b}}{6} \left(\frac{1}{0.19} + \frac{1}{0.36} \right) \\&= \frac{2^{-2b}}{6} (5.26 + 2.778) \\&= 1.34 \times 2^{-2b}\end{aligned}$$

比较三种结构误差大小：

$$22.46 \times 2^{-2b} > 15.2 \times 2^{-2b} > 1.34 \times 2^{-2b}$$



结果说明直接型结构的误差最大，其次是级联结构，最小是并联结构。这是因为直接型结构中所有舍入误差都要经过全部网络的反馈环节，使误差在反馈过程中积累起来，总的误差就很大。在级联型结构中，每个舍入误差值通过其后面的反馈环节，而与前面的无关，因此误差比直接型小。并联结构中每个环节的舍入误差只通过本身的反馈环节，与其它环节无关，积累作用最小，所以误差最小。



这个结论对IIR滤波器具有普遍意义。所以从有效字长效应看，不论直接 I 型或直接 II 型都是最差的，高阶系统时要避免使用。级联结构较好，并联结构最好，具有最小的运算误差。

结果还说明无论那种结构，误差都与字长 b 有关， b 越大，误差越小。




■ 定点FIR系统舍入运算误差分析

1、输出噪声方差


N 阶的FIR系统差分方程为
$$y(n) = \sum_{m=0}^{N-1} h(m)x(n-m)$$

系统的直接(卷积)形式运算模型如图所示





系统的直接(卷积)形式舍入运算误差统计模型



每做一次舍入乘法产生一次误差。在同一时刻 n ，要产生 N 个舍入误差，将其等效为 N 个噪声源 $e_0(n), e_1(n), \dots, e_{N-1}(n)$ ，当 n 变化时形成随机序列。



同样对 $e_i(n)$ ($i=0,1,2,\dots,N-1$)作如下假设

(1)所有误差 $e_i(n)$ 是平稳的零均值白噪声序列;

(2)每个误差在量化误差范围内均匀等概分布, 方差为

$$\sigma_{ei}^2 = \frac{2^{-2b}}{12}, \quad i=0,1,2,\dots,N-1;$$

(3)两个不同噪声源彼此不相关;

(4)误差 $e_i(n)$ 与输入 $x(n)$ 不相关, 且与系统中任何节点变量不相关, 从而与输出 $y(n)$ 也不相关。



此时输出为

$$\hat{y}(n) = y(n) + \sum_{n=0}^{N-1} e_i(n) = y(n) + f(n)$$

则输出方差

$$\sigma_f^2 = \sum_{n=0}^{N-1} \sigma_{en}^2 = N \cdot \frac{2^{-2b}}{12}$$

结果表明，FIR系统定点舍入运算误差直接到达输出端，与系统的系数无关；误差与字长 b 及系统的阶次 N 有关， b 越大或 N 越小，误差越小。



从以上简单比较我们可以看到IIR滤波器与FIR滤波器各有所长，在实际应用时要从多方面考虑来加以选择。从使用要求来看，如对相位要求不敏感的语言通讯等，选用IIR较为合适。而对图像信号处理、数据传输等以波形携带信息的系统，一般对线性相位要求较高，这时采用FIR滤波器较好。当然，在实际设计中，还应综合考虑经济上的要求以及计算工具的条件等多方面的因素。



第9章作业

9.2 ; 9.5 ; 9.12